

# BNPL不正検知におけるアーキテクチャの進化 : Transformerベース深層学習モデルのサー ベイ

## 第1章 エグゼクティブサマリー

本レポートは、後払い決済(BNPL)サービスにおける不正検知の領域で、最新の深層学習モデル、特にTransformerアーキテクチャに焦点を当てた包括的な技術サーベイを提供する。中核となる論点は、現在、表形式データにおける不正検知の分野では勾配ブースティング決定木(GBDT)が堅牢かつ効率的なベンチマークとして君臨している一方で、大規模な自己教師あり学習(SSL)によって強化されたTransformerベースの深層学習モデルが、性能において新たな最高水準(State-of-the-Art)を達成する明確な可能性を示しているという点にある。しかしながら、その産業界への本格的な導入は、計算コスト、リアルタイム推論におけるレイテンシ、そしてモデルの解釈可能性という、看過できない重大な課題によって現在もお抑制されている。

### 主要な調査結果の要約

本調査を通じて明らかになった主要な知見は、以下の通りである。

- 市場の急成長と不正リスクの増大: BNPL市場は驚異的な速度で拡大しており、日本の市場規模は2024年に210億米ドルに達し、2028年度には2.8兆円規模への成長が予測されている<sup>1</sup>。この急成長は、高度な手口を用いる不正行為者にとって魅力的な環境を生み出し、従来の不正検知システムの限界を露呈させている。
- GBDTの優位性: XGBoostやLightGBMといったGBDTモデルは、構造化データに対する高い性能、推論速度、そして効率性から、業界の標準的地位を確立している。これは、Kaggleなどのデータサイエンスコンペティションの結果からも一貫して裏付けられている<sup>4</sup>。
- 深層学習へのシフト: 2022年から2024年にかけて、不正検知における深層学習の研究が急増している。特に、時系列データのパターンを捉えるLSTMや、エンティティ間の関係性をモデル化するグラフニューラルネットワーク(GNN)が有望視される中、Transformerが研究の中心的な焦点として浮上している<sup>8</sup>。

- **Transformerの潜在能力:** Transformerの最大の利点は、自己注意機構 (Self-Attention Mechanism) により、複雑で非線形な特徴量間の相互作用を自動的にモデル化できる点にある。さらに、GBDTにはない能力として、大量のラベルなしデータを活用した事前学習 (Pre-training) が可能であり、これによりモデルの汎化性能を飛躍的に向上させることができる<sup>10</sup>。
- **導入への障壁:** Transformerの広範な採用を妨げる主な要因は、その高い計算コストである。特に、BNPLサービスに不可欠リアルタイムでの低レイテンシ推論を実現するには、多大なインフラ投資と高度な最適化技術が要求される<sup>13</sup>。加えて、その「ブラックボックス」的な性質は、規制遵守やリスク分析の観点から大きな課題となっている<sup>16</sup>。

## 戦略的展望

不正検知技術の将来的な軌道は、単一のモデルアーキテクチャに依存するのではなく、複数の技術を組み合わせたハイブリッドシステムへと向かうことが予測される。Transformerの卓越した表現学習能力と、GBDTの効率性や解釈可能性を組み合わせるアプローチ、さらにはモデルの量子化や蒸留といった最適化技術の進展が、Transformerの性能と業界の実用的な要求との間のギャップを埋める鍵となるであろう。長期的には、金融機関がプライバシーを保護しつつ共同でモデルを訓練する連合学習 (Federated Learning) のような先進的なパラダイムが、業界全体の不正対策能力を新たなレベルに引き上げる可能性がある。

---

## 第2章 BNPL不正のランドスケープ: 成長とリスクの交差点

後払い決済 (BNPL) 市場の急拡大は、消費者と事業者双方に新たな利便性をもたらした一方で、これまでにない規模と巧妙さを持つ不正リスクの温床となっている。このセクションでは、BNPL市場のダイナミクス、その脆弱性、具体的な不正手口の分類、そして既存の対策技術の限界について詳述する。

### 市場のダイナミクスと脆弱性

BNPL市場は、世界的に見ても、また日本国内においても、爆発的な成長を遂げている。市場規模は2023年度に1.5兆円を超え、2028年度には2.8兆円に達すると予測されている<sup>3</sup>。日本の市場だけでも、2024年には210億米ドル規模に達し、今後も高い成長率が見込まれている<sup>1</sup>。この成長の原動力となっているのは、クレジットカードを持たない、あるいは利用に抵抗がある若年層などを中心とし

たユーザー層の獲得である。

NP後払い、Paidy、atone、そしてGMOペイメントゲートウェイが提供するアトカラといった主要なBNPLサービスは、共通して「今買って、後で支払う」というシンプルな価値提案を核に据えている<sup>17</sup>。これらのサービスのビジネスモデルにおける最大の競争優位性の一つが、ユーザーにとっての「摩擦のない(frictionless)」決済体験である。特に、数秒から数分で完了する「リアルタイム与信」は、購入者の離脱を防ぎ、コンバージョン率を高めるための重要な機能として位置づけられている<sup>25</sup>。

しかし、この即時性と利便性は、セキュリティ上の脆弱性と表裏一体の関係にある。従来のクレジットカード発行時に行われるような厳格な本人確認プロセスを簡略化し、迅速な与信判断を行うビジネスモデルは、不正行為者にとって格好の攻撃対象(アタックサーフェス)となる。取引の瞬間に実行可能な不正チェックの複雑さには自ずと限界があり、この制約がBNPL特有の脆弱性を生み出している。この事業上の要請とセキュリティリスクとの間の緊張関係こそが、BNPL不正検知システムに求められる技術的要件を定義する根源的な要因である。すなわち、求められるのは単に高い精度を持つモデルではなく、リアルタイム取引の厳しいレイテンシ制約の中で、極めて高速に推論を実行できるモデルなのである。この点が、本レポートで後に詳述する、計算集約的な大規模深層学習モデルの導入における核心的な課題へと繋がっていく。

## BNPL不正スキームの分類

BNPLサービスを標的とする不正手口は多様化・高度化しており、主要なものとして以下が挙げられる。

- なりすまし(**Identity Theft & Impersonation**): 最も古典的かつ一般的な手口であり、窃取した個人情報(氏名、住所、電話番号など)を用いて第三者になりすまし、商品を購入する行為である<sup>31</sup>。一部のサービス提供事業者のサポート対応からは、現状の審査が氏名や住所などの情報の整合性チェックに留まっており、積極的ななりすまし防止策がシステム的に実装されていないケースがあることが示唆されている。多くの場合、不正が発覚した後の事後的なキャンセル対応に依存しており、予防的な対策が追いついていない実態がうかがえる<sup>31</sup>。
- シンセティックアイデンティティ不正(**Synthetic Identity Fraud**): 実在の個人情報と架空の情報を組み合わせて、全く新しい架空の身元(シンセティックアイデンティティ)を作成し、それを用いてアカウントを開設・利用する手口である。実在しない人物であるため、従来の信用情報データベースとの照合では検知が困難であり、より高度な検知技術が求められる。
- アカウントテイクオーバー(**Account Takeover, ATO**): 正規ユーザーのアカウントに不正にアクセスし、登録されている個人情報や決済情報を悪用して商品を購入する手口である。フィッシングやマルウェアなど、他のサイバー攻撃と組み合わせて実行されることが多い。
- フィッシングおよびソーシャルエンジニアリング: BNPL事業者や有名ECサイトを装った偽の電子メールやSMSを送信し、ユーザーを偽のウェブサイトへ誘導してログイン情報や認証コードを窃取する手口である。PaidyやNP後払いといった事業者は、ユーザーに対して身に覚えのないメールに含まれるリンクを開かないよう、また認証コードを第三者に教えないよう繰り返し注意喚起を

行っている<sup>32</sup>。これは、この種の手口が依然として深刻な脅威であることを示している。

## 現行の緩和技術の限界

現在、BNPL事業者が導入している不正対策は、複数の技術を組み合わせた多層防御が基本となっているが、それぞれに限界が存在する。

- **ルールベースシステム:**「特定のIPアドレスからのアクセスをブロックする」「短時間に高額な取引が連続した場合にアラートを出す」といった、専門家が事前に定義したルールに基づいて不正を判断するシステムである。事業者の特定の要件をルール化できる柔軟性を持つ一方で、その性質上、静的であるという大きな欠点を持つ。日々巧妙化し、変化する不正の新たな手口やパターンに対応できず、未知の攻撃に対しては無力である<sup>35</sup>。
- **基本的な機械学習モデル:** ルールベースシステムの限界を克服するために、AIや機械学習を活用した不正検知システムが導入されている。これらのモデルは、過去の取引データから不正のパターンを自動的に学習するため、ルールベースよりも高い精度を発揮し、新たな不正手口にもある程度適応できる<sup>35</sup>。しかし、多くの従来型機械学習モデルは、その性能を最大限に引き出すために「特徴量エンジニアリング」と呼ばれるプロセスに大きく依存する。これは、専門家がドメイン知識を駆使して、生のデータからモデルが学習しやすいような有益な特徴量(例えば、過去24時間の取引回数や平均取引額など)を手動で設計・作成する作業であり、多大な時間と労力を要する<sup>36</sup>。
- **eKYC(electronic Know Your Customer):** なりすまし対策として、オンラインで完結する本人確認(eKYC)の導入が進んでいる。Paidyやatoneなどの事業者は、AIを活用した顔認証と身分証明書の照合によって本人確認を強化し、不正利用の防止を図っている<sup>37</sup>。これは不正対策の有効な一助となるが、全ての取引でeKYCを要求することはユーザー体験を損なう可能性があり、また、eKYCプロセス自体を突破しようとする高度な攻撃(ディープフェイクなど)のリスクも存在する。

これらの既存技術は一定の効果を発揮するものの、不正行為の進化のスピードに追いつくためには、より高度で、より自動化された検知パラダイムへの移行が不可欠となっている。

---

## 第3章 表形式データ不正検知におけるGBDTの支配

BNPL取引データのような構造化された表形式データの分析において、勾配ブースティング決定木(GBDT)は、長年にわたり業界のデファクトスタンダードとして君臨してきた。その高い予測性能と効率性は、他の多くのアルゴリズムを凌駕し、不正検知システムの根幹を成してきた。このセクションでは、GBDTがなぜこれほどまでに支配的な地位を築いたのか、その成功を支えるエコシステム、そし

て内在する課題について掘り下げる。

## GBDTの業界標準としての地位

XGBoost、LightGBM、CatBoostといったGBDTの実装は、表形式データに対する分類タスクにおいて、現在の最高水準の技術と広く見なされている。その有効性は、学術研究の枠を超え、実世界の複雑なデータセットを扱う多くのデータサイエンスコンペティションで繰り返し証明されてきた。特に、Kaggleが主催する「IEEE-CIS Fraud Detection」や「Home Credit Default Risk」といった大規模な金融不正検知・信用リスク評価コンペティションでは、上位入賞チームのソリューションのほぼ全てがGBDTを中核モデルとして採用している<sup>4</sup>。これらのコンペティションは、業界のベストプラクティスを反映する強力な指標であり、GBDTの実用的な優位性を明確に示している。

## 特徴量エンジニアリングの力

GBDTの成功は、アルゴリズム自体の性能だけに起因するものではない。むしろ、その性能は、人間による高度な特徴量エンジニアリングと密接に結びついている。GBDTはデータ内のパターンを発見することに長けているが、その能力は、モデルに与えられる特徴量の質に大きく左右される。不正検知の文脈では、金融犯罪対策の専門家が持つ知見を基に、「犯罪パターン」を定義する特徴量エンジニアリングがモデルの精度を決定づける重要なプロセスとなる<sup>49</sup>。

不正検知で一般的に作成される特徴量の例は以下の通りである。

- **集約特徴量 (Aggregation Features):** 特定のユーザー、デバイス、IPアドレスなどでデータをグループ化し、様々な時間枠(例: 過去1時間、24時間、1週間)における取引金額の合計、平均、最大値、標準偏差などを計算する<sup>36</sup>。これにより、個々の取引の文脈を捉える。
- **頻度・速度チェック (Frequency/Velocity Checks):** 一定期間内における取引回数、失敗したログイン試行回数、利用した加盟店のユニーク数などをカウントする<sup>4</sup>。異常に高い頻度は、不正の兆候である可能性が高い。
- **相互作用特徴量 (Interaction Features):** 既存の特徴量を組み合わせて新たな特徴量を作成する。例えば、取引金額をそのユーザーの過去の平均取引額で割ることで、相対的な取引の大きさを表現する。

このアプローチは、システムの「知能」の大部分が、モデルそのものではなく、人間によって設計された特徴量に内包されることを意味する。モデルは強力なパターン発見器として機能するが、それはあくまで事前に整理され、情報が豊富化されたデータ表現に対してである。後に詳述するTransformerのような深層学習モデルは、このパラダイムに挑戦する。すなわち、生のデータに近い入力から特徴量の相互作用を自動的に学習することを目指すのである。したがって、GBDTとTransformerの比較



は、単なるアルゴリズム間の比較ではなく、特徴量エンジニアリングを中心とする従来型ワークフローと、表現学習を中心とする新しいワークフローとの間の比較という、より大きな構図で捉える必要がある。

## 不均衡データという根源的課題

不正検知における最も根源的かつ困難な課題の一つが、データの極端な不均衡性である。「超不均衡データ」とも呼ばれるこの状況では、不正取引の件数が正常取引に比べて圧倒的に少なく、その比率は数万から数十万分の一に達することもある<sup>49</sup>。このようなデータセットで機械学習モデルを訓練すると、モデルは大多数を占める正常クラスを予測するだけで高い正解率 (Accuracy) を達成できてしまうため、少数派である不正クラスをほとんど検知できなくなる (偽陰性、False Negative が高くなる) という問題が生じる<sup>52</sup>。

この課題に対処するため、GBDTモデルの訓練においては、データセットのクラス分布を調整するためのサンプリング技術が一般的に用いられる。

- **アンダーサンプリング (Undersampling)**: 多数派である正常クラスのサンプルをランダムに削減し、不正クラスのサンプル数に近づける手法<sup>53</sup>。計算コストを削減できる利点があるが、削減の過程で重要な情報を失うリスクがある。
- **オーバーサンプリング (Oversampling)**: 少数派である不正クラスのサンプルを複製してデータ数を増やす手法。単純な複製はモデルの過学習を招く可能性がある。
- **SMOTE (Synthetic Minority Over-sampling Technique)**: オーバーサンプリングの改良版であり、不正クラスの既存のサンプルとその近傍のサンプルとの間に、線形補間によって新たなサンプルを人工的に合成する手法<sup>52</sup>。これにより、情報を失うことなく、また単純な複製による過学習を避けながら、クラスの不均衡を緩和することができる。

これらの技術は、GBDTを中心とした不正検知エコシステムの重要な構成要素であり、新しいモデルアーキテクチャがGBDTに取って代わるためには、この不均衡データ問題に対して、同等かそれ以上に効果的な解決策を提示する必要がある。

---

## 第4章 複雑なデータパターンに対する深層学習パラダイムシフト

GBDTが特徴量エンジニアリングを前提とするアプローチで成功を収める一方で、深層学習は、データから直接、複雑で階層的なパターンを自動的に学習するという、異なるパラダイムを提示する。この能力は、手動での特徴量設計への依存を低減させ、より巧妙で未知の不正パターンを捉える可能

性を秘めている。近年の研究動向は、不正検知分野におけるこのパラダイムシフトが加速していることを明確に示している。

## 不正検知における深層学習の導入

深層学習モデルは、その多層的なニューラルネットワーク構造を通じて、データの中に存在する高次の相関関係や非線形なパターンを捉えることができる。これは、不正検知において極めて重要である。なぜなら、不正行為はしばしば、単一の特徴量だけでは捉えられない、複数の要因が複雑に絡み合った結果として現れるからである。

2019年から2024年にかけて発表された金融不正検知に関する学術論文を体系的にレビューした研究によると、特に2022年以降、深層学習を用いた研究の数が急激に増加していることが確認されている<sup>8</sup>。このトレンドは、利用可能なデータの増大、計算能力の向上、そしてアルゴリズムの成熟が相まって、深層学習が金融不正という複雑な問題に対する実行可能なソリューションとして認識され始めたことを示している。

## 時系列データのための再帰型ニューラルネットワーク(LSTM)

BNPLを含む金融取引データは、本質的に時間的な順序を持つ系列データである。あるユーザーが行う一連の取引は、単なる独立した点の集合ではなく、時間軸に沿った連続的な行動シーケンスを形成する。このようなデータの特性を捉えるために、再帰型ニューラルネットワーク(RNN)、特にその発展形であるLong Short-Term Memory(LSTM)が注目されている。

LSTMは、ネットワーク内に「記憶セル」と呼ばれるメカニズムを持つことで、過去の情報を長期間保持し、現在の入力と組み合わせる処理することができる<sup>58</sup>。これにより、ユーザーの通常の支出行動パターン(例えば、平均的な取引額、よく利用する加盟店、取引の時間帯など)を時系列的に学習することが可能となる。そして、その学習したパターンから大きく逸脱するような取引(例えば、普段は少額の買い物しかしないユーザーによる突然の高額決済)を異常として検知することができる。前述の体系的レビューにおいても、不正検知分野におけるLSTMの利用は「最も顕著で持続的な成長」を遂げており、その背景には系列データという金融取引データの性質があると分析されている<sup>8</sup>。

## 関係性に基づく不正のためのグラフニューラルネットワーク(GNN)

巧妙な不正行為は、単一のユーザーの行動だけでなく、複数のエンティティ(ユーザー、デバイス、

加盟店、IPアドレスなど)が相互に関連し合ったネットワークとして現れることが多い。例えば、一つの盗難クレジットカード情報が複数の不正アカウントで使い回されたり、不正グループが複数の加盟店と結託して架空取引を行ったりするケースである。このような「関係性」に潜む不正を検出するために、グラフニューラルネットワーク(GNN)が強力なツールとして登場した。

GNNは、エンティティを「ノード」、その間の関係(取引、同一デバイスの使用など)を「エッジ」とするグラフ構造でデータを表現し、その上で学習を行う。GNNの基本的なアイデアは、各ノードの特徴を、その近傍ノードの情報を集約することによって更新していくことにある。このプロセスを繰り返すことで、各ノードは自身の局所的な情報だけでなく、グラフ全体の構造的な文脈を反映した表現(埋め込みベクトル)を獲得する。これにより、個々の取引を独立して見るだけでは発見不可能な、不正コミュニティや組織的な詐欺リングといった異常な連結パターンを特定することが可能になる。GNNは「複雑な関係性パターンを捉えるのに非常に長けている」と評価されている。

近年のGNN研究のトレンドとしては、リアルタイムで取引が追加されていく動的なグラフ構造への対応や、グラフ内で特に重要なノードやエッジに重み付けを行うグラフアテンション機構の導入などが挙げられる。自己教師あり学習をグラフベースの不正検知に応用したGraphGuardのような研究は、この分野の最先端を示している。

LSTMとGNNの台頭は、不正という問題が単一の側面からだけでは捉えきれないことを示唆している。不正行為には、個人の行動履歴からの逸脱という「時間的」側面と、複数の主体が関与する「関係的」側面が存在する。LSTMは前者の検出に、GNNは後者の検出にそれぞれ特化したアーキテクチャであると言える。このことは、より包括的な不正検知システムの構築には、これらの異なる側面を同時に捉えることができる、さらに高度な、あるいはハイブリッドなアーキテクチャが必要であることを示唆している。この文脈において、系列処理能力と強力な表現学習能力を併せ持つTransformer、さらにはその概念をグラフ構造に拡張したGraph Transformerが、次世代の統一的モデルとしての可能性を秘めているのである<sup>60</sup>。

---

## 第5章 表形式データのためのTransformerアーキテクチャへの技術的深掘り

自然言語処理(NLP)の分野で革命的な成功を収めたTransformerアーキテクチャは、その強力な表現学習能力から、近年、表形式データの領域、特に不正検知への応用が活発に研究されている。このセクションでは、Transformerの核心技術である自己注意機構がどのように表形式データに適応されるのか、主要なモデルアーキテクチャ、そして既存のGBDTモデルとの性能比較について、技術的な詳細に踏み込んで解説する。

言語から会計帳簿へ: 表形式データへの自己注意機構の適応



Transformerの根幹をなす自己注意機構(Self-Attention Mechanism)は、入力シーケンス内のある要素の表現を計算する際に、シーケンス内の他の全ての要素との関連性の重みを動的に計算し、その重みに基づいて情報を集約する仕組みである<sup>11</sup>。NLPでは、文中の各単語が他のどの単語と強く関連しているかを学習することで、文脈に応じた豊かな単語表現を獲得する。

この概念を表形式データに適用する場合、文中の「単語」は、一つの取引記録に含まれる「特徴量」(取引金額、加盟店カテゴリ、利用時刻など)に置き換えられる。自己注意機構は、ある取引記録内の全ての特徴量間の相互作用を学習し、各特徴量に対して「文脈化された埋め込み(contextual embedding)」を生成する<sup>62</sup>。これにより、例えば「高額な取引」という特徴量が、「深夜」という時間特徴量や「海外の新規加盟店」という特徴量と同時に出現した場合に、より高い不正リスクを持つ、といった複雑な非線形関係をモデルが自動的に捉えることが可能になる。

このアプローチを実装した代表的なモデルとして、以下の二つが挙げられる。

- **TabTransformer:** カテゴリカル特徴量に特化して自己注意機構を適用するモデル。まず、各カテゴリカル特徴量を埋め込みベクトルに変換し、それらをTransformer層に入力して文脈化された埋め込みを生成する。一方、数値特徴量はTransformer層を通さず、別途MLP(多層パーセプトロン)などで処理され、最終的にカテゴリカル特徴量の出力と連結されて予測に使われる<sup>62</sup>。
- **FT-Transformer (Feature Tokenizer Transformer):** より汎用的なアプローチであり、カテゴリカル特徴量と数値特徴量の両方を統一的な埋め込みベクトル(トークン)に変換し、それらをまとめてTransformer層で処理する。この「全ての特徴量をトークン化する」という点がTabTransformerとの大きなアーキテクチャ上の違いであり、「Revisiting Deep Learning Models for Tabular Data」という独創的な論文で提案された中核的なアイデアである<sup>66</sup>。

## 特徴量トークナイザ: 構造化データへのゲートウェイ

FT-Transformerの性能を理解する上で最も重要な構成要素が「特徴量トークナイザ(Feature Tokenizer)」である。これは、構造化された表形式データの各特徴量を、Transformerが処理可能な統一的な埋め込みベクトル空間に射影する役割を担う<sup>66</sup>。

- カテゴリカル特徴量の処理: 各カテゴリ(例:「加盟店IDがA」「国が日本」)は、NLPにおける単語埋め込みと同様に、一意の学習可能な埋め込みベクトルに対応付けられる。これは、カテゴリ間の潜在的な意味関係を密なベクトルで表現する標準的な手法である。
- 数値特徴量の処理: ここがFT-Transformerの独創的な部分である。スカラー値である数値特徴量  $x_{\text{num}}$  は、単純な線形変換によって埋め込みベクトル  $T(x_{\text{num}})$  に変換される。

$$T(x_{\text{num}}) = W \cdot x_{\text{num}} + b$$

ここで、 $W$  は学習可能な重みベクトル、 $b$  は学習可能なバイアスベクトルである。この操作により、連続的なスカラー値が、カテゴリカル特徴量の埋め込みと同じ次元の高次元ベクトル空間に射影される。これにより、数値特徴量とカテゴリカル特徴量を区別なく、後続のTransformer層で

統一的に扱うことが可能になる。

これらの処理を経て生成された各特徴量の埋め込みベクトルのシーケンスの先頭には、特別な（Classification）トークンが追加される。このトークンは、他の特徴量トークンと同様にTransformer層を通過し、最終層から出力された ``トークンに対応する埋め込みベクトルが、取引記録全体の集約的な表現として利用され、最終的な不正確率を予測するための分類器（通常はMLP）への入力となる<sup>66</sup>。

## 性能ベンチマーキング：Transformer vs. GBDT

TransformerがGBDTを凌駕するかどうかについては、学術文献においても議論が分かれており、「普遍的に優れた単一の解決策はまだ存在しない」というのが現状のコンセンサスである<sup>66</sup>。

- **Transformerの優位性を示す研究：**
  - FT-Transformerを提案した論文では、多くのベンチマークデータセットにおいて、FT-Transformerが他の深層学習モデルの中で最高の性能を示し、アンサンブル学習を行うことでGBDTを上回るケースがあることが報告されている<sup>66</sup>。
  - 「Credit Card Fraud Detection Using Advanced Transformer Model」と題された論文では、著者らのデータセットにおいて、TransformerがF1スコアで0.998という驚異的な性能を達成し、XGBoostの0.95を大幅に上回ったと主張している<sup>68</sup>。
- **GBDTの優位性を示す研究：**
  - FT-Transformerの論文自体も、ハイパーパラメータを適切にチューニングした場合、「一部のデータセットではGBDTが優位に立ち始める」ことを認めている<sup>66</sup>。
  - 複数の文献で、表形式データに対するTransformerモデルが、GBDTのような古典的な機械学習アルゴリズムの性能を超えることに苦戦する場合があると言及されている。

この性能に関する議論を明確化するため、主要な研究から報告されている性能指標を以下の表にまとめる。

表1: 不正検知ベンチマークにおけるTransformerとベースラインモデルの性能比較

| データセット            | モデル     | 評価指標 1 (AUC) | 評価指標 2 (AP / F1-Score) | 出典 |
|-------------------|---------|--------------|------------------------|----|
| クレジットカード不正 (2023) | XGBoost | 0.99         | 0.95 (F1)              | 10 |
| クレジットカード          | TabNet  | 0.98         | 0.93 (F1)              | 10 |

|                                       |                             |             |              |    |
|---------------------------------------|-----------------------------|-------------|--------------|----|
| 不正 (2023)                             |                             |             |              |    |
| クレジットカード<br>不正 (2023)                 | Transformer                 | 0.99        | 0.998 (F1)   | 10 |
| クレジットカード<br>不正 (2013)                 | XGBoost                     | 0.96        | 0.92 (F1)    | 10 |
| クレジットカード<br>不正 (2013)                 | Transformer                 | 0.98        | 0.998 (F1)   | 10 |
| クレジットカード<br>取引                        | GAT (GNN)                   | ~0.87       | -            | 69 |
| クレジットカード<br>取引                        | TGTN (Graph<br>Transformer) | ~0.91       | ~0.91 (AP)   | 69 |
| California<br>Housing<br>(Regression) | CatBoost<br>(GBDT)          | -           | 0.489 (RMSE) | 66 |
| California<br>Housing<br>(Regression) | ResNet                      | -           | 0.560 (RMSE) | 66 |
| California<br>Housing<br>(Regression) | FT-Transforme<br>r          | -           | 0.536 (RMSE) | 66 |
| Adult<br>(Classification)             | CatBoost<br>(GBDT)          | 0.929 (AUC) | -            | 66 |
| Adult<br>(Classification)             | ResNet                      | 0.921 (AUC) | -            | 66 |
| Adult<br>(Classification)             | FT-Transforme<br>r          | 0.924 (AUC) | -            | 66 |

注: 評価指標やデータセットの分割方法が研究ごとに異なるため、直接的な比較には注意が必要で

ある。この表は、各研究内での相対的な性能傾向を示すことを目的としている。

## 事前学習の力：自己教師あり学習(SSL)という戦略的優位性

TransformerがGBDTに対して持つ最も本質的かつ戦略的な優位性は、そのアーキテクチャが大規模な事前学習に適している点にある。不正検知の分野では、不正ラベルが付与されたデータは極めて希少である一方、ラベルのない正常な取引データは膨大に存在する。GBDTは、そのアルゴリズムの性質上、ラベル付きデータでしか訓練できない。

対照的に、Transformerは、自己教師あり学習(SSL)というパラダイムを用いて、大量のラベルなし取引データで事前学習を行うことができる。SSLでは、データ自体から擬似的なタスク(例えば、系列の一部をマスクし、それを予測させるタスク)を作成し、それを解くことを通じて、モデルにデータの根源的な構造やパターンを学習させる。このようにして金融取引データの「言語」を事前に学習したTransformerモデルを、その後、少量のラベル付き不正データを用いて特定の不正検知タスクに適応(ファインチューニング)させるのである。

この「転移学習」アプローチは、モデルが汎用的なデータ表現を学習することを可能にし、ラベル付きデータへの依存を低減させ、最終的により高い汎化性能をもたらす<sup>10</sup>。Booking.comでの不正検知に関する研究では、このSSLを用いた事前学習こそが、チューニングされたGBDTを凌駕する性能を達成するための鍵であったと明確に述べられている。

この事実は、Transformerの導入が単なるモデルの置き換えではないことを示唆している。それは、データ戦略そのものの変革を要求する。少量のラベル付きデータでゼロからモデルを訓練する従来のアプローチから、ペタバイト級のラベルなしデータを活用して基盤モデルを構築し、それを特定のタスクに適応させるという、より大規模で野心的なアプローチへの移行である。この戦略的コミットメントの大きさこそが、Transformerの真のポテンシャルを引き出すための代償であり、同時に多くの組織にとっての参入障壁ともなっている。

---

## 第6章 最先端の応用と研究フロンティア

Transformerアーキテクチャは、その柔軟性と拡張性から、単体での利用に留まらず、他のモデルとの融合や、特定の問題領域に特化した応用研究が急速に進んでいる。本セクションでは、2023年から2025年にかけて発表された最先端の研究事例を分析し、ハイブリッドモデルやアーキテクチャ融合の動向を探る。

## 近年の研究事例分析(2023-2025年)

- 事例1: Booking.comにおける実世界での大規模応用 (S\_R91, S\_R95)  
この研究は、eコマースの巨大プラットフォームにおけるTransformerの実用的な有効性を証明した画期的な事例である。彼らのアプローチの核心は、FT-Transformerアーキテクチャを、自己教師あり学習(SSL)を用いた大規模な事前学習と組み合わせた点にある。特に注目すべきは、ラベル付けにバイアスがかかっている可能性のある本番データを含む、利用可能な全てのデータを事前学習に活用したことである。これにより、データの根源的なパターンを学習した強力な基盤モデルを構築し、その後、クリーンでバイアスのない少量のラベル付きデータセットでファインチューニングを行った。結果として、この手法は、徹底的にチューニングされたGBDTモデルを、オフライン評価だけでなく、実際のビジネス指標を用いたオンラインA/Bテストにおいても統計的に有意な差をつけて上回り、Transformerの産業応用における優位性を実証した。
- 事例2: 「Advanced Transformer Model」による高性能の追求<sup>68</sup>

この研究は、クレジットカード不正検知において、Transformerモデルがほぼ完璧に近い性能(F1スコア0.998)を達成したと報告している。この驚異的な結果の背景にも、事前学習とファインチューニングのパラダイムが重要な役割を果たしていることが示唆されている。この研究は、適切なデータと学習戦略の下で、Transformerが従来のベンチマークを大幅に超えるポテンシャルを秘めていることを示す一方で、その結果の再現性や一般性についてはさらなる検証が求められる。

- 事例3: クラウド最適化とリアルタイムストリーミングへの応用<sup>69</sup>

この研究は、リアルタイムで発生する大量の取引データを処理するために、クラウド環境に最適化されたTransformerモデルの展開に焦点を当てている。特に興味深いのは、グラフアテンショントランスフォーマー(Graph Attention Transformer)を用いて、取引データからトポロジ的特徴(エンティティ間の関係性)と時系列特徴(取引の順序)を自動的に学習するアプローチを採用している点である。これは、GNNの持つ関係性学習能力とTransformerの系列処理能力を融合させる試みであり、ベースラインモデルを大幅に上回る性能を達成したと報告されている。この研究は、Transformerが単なる表形式データ処理ツールから、より複雑なデータ構造を扱うための統合的なフレームワークへと進化していることを示している。

## ハイブリッドモデルとアーキテクチャの融合

Transformerの自己注意機構が持つ強力な特徴抽出能力を、他のアーキテクチャの利点と組み合わせることで、さらなる性能向上を目指すハイブリッドモデルの研究が活発化している。

- **CNN-Transformerハイブリッド:** 畳み込みニューラルネットワーク(CNN)は、局所的な特徴を抽出することに長けている。この特性を利用し、まずCNNを用いてデータから初期的な特徴マップを生成し、その出力をTransformerに入力して特徴間の大域的な依存関係をモデル化するという



アプローチが提案されている<sup>70</sup>。これは、画像認識分野で成功したアプローチを表形式データに応用する試みである。

- **グラフトランスフォーマー (Graph Transformers)**: これは、不正検知分野における最も重要な研究フロンティアの一つである。グラフトランスフォーマーは、GNNのグラフ構造を扱う能力と、Transformerの自己注意機構を組み合わせることを目的としている<sup>60</sup>。これにより、不正リングのような複雑な関係性を持つエンティティ群の動的な時間変化を捉えることが可能になると期待されている。例えば、ある不正グループが時間と共に関係性を変化させながら活動するようなシナリオにおいて、そのパターンを端から端まで(end-to-end)で学習できる可能性がある。
- **Transformerと伝統的機械学習の組み合わせ**: Transformerを特徴抽出器として利用するアプローチも存在する。「Transformer-LOF-Random Forest」モデルの研究では、まずTransformerを用いてデータから高次元で文脈化された特徴表現を抽出し、その特徴量を入力として、局所外れ値因子(LOF)やランダムフォレストといった他のアルゴリズムで最終的な分類を行う<sup>9</sup>。これは、Transformerの強力な表現学習能力と、他のモデルが持つ異なるバイアスや特性を組み合わせるアンサンブル学習の一形態と見なすことができる。

これらの研究動向は、不正検知という複雑な問題に対して、単一の万能なアーキテクチャが存在するわけではなく、問題の異なる側面に特化した複数の技術を創造的に組み合わせることが、性能向上の鍵であることを示している。

---

## 第7章 実装上の課題と今後の研究軌道

Transformerモデルが理論上および一部の実証研究で示した高い潜在能力にもかかわらず、その技術をBNPLのようなリアルタイム性が要求される金融サービスに本格導入するには、いくつかの重大な技術的・運用的ハードルが存在する。本セクションでは、推論レイテンシ、モデルの解釈可能性、そしてデータに関する課題に焦点を当て、これらの障壁と、それらを克服するための今後の研究の方向性について論じる。

### レイテンシのジレンマ: リアルタイム推論のスケーラビリティ

BNPLサービスの不正検知システムは、ユーザーの決済体験を損なうことなく、ミリ秒単位での応答が求められる。しかし、Transformerアーキテクチャ、特にその心臓部である自己注意機構は、入力シーケンス長(この文脈では特徴量の数)に対して二乗の計算量( $O(n^2)$ )を必要とするため、本質的に計算コストが高い。

- **性能と速度のトレードオフ**: GBDTモデルが極めて高速な推論速度で知られているのに対し、PyTorchなどのフレームワーク上で素朴に実装されたTransformerモデルの推論は、特に大規模なモデルになると、リアルタイム要求を満たせないほど遅くなる可能性がある<sup>13</sup>。このため、

Transformerの導入は、潜在的な精度向上と、インフラコストの増大およびレイテンシ悪化のリスクとの間の直接的なビジネス上のトレードオフを伴う<sup>15</sup>。

- 最適化技術の必要性: このレイテンシ問題を克服するためには、高度な最適化技術が不可欠となる。具体的には、NVIDIAのTensorRTやONNX Runtimeといった推論エンジンを用いてモデルをコンパイルし、演算の融合やハードウェアに特化したカーネルの利用を図ること、また、モデルの重みを32ビット浮動小数点数(FP32)から16ビット(FP16)や8ビット整数(INT8)へと変換する量子化(Quantization)を行い、計算量とメモリ使用量を削減することが一般的なアプローチである<sup>14</sup>。これらの最適化を施すことで、ミリ秒未満のレイテンシを達成することも可能であるが、それには専門的な知識とエンジニアリングの労力が必要となる。

## 解釈可能性の要請

金融サービスは、多くの国で厳格な規制の対象となっており、モデルによる意思決定(例えば、取引の拒否)に対して、その根拠を説明する能力が求められることがある。これは、規制当局への報告義務や、顧客からの問い合わせに対応するために不可欠である。

- ブラックボックス問題: Transformerを含む深層学習モデルは、その複雑な内部構造から「ブラックボックス」と批判されることが多い<sup>16</sup>。モデルがなぜ特定の取引を不正と判断したのかを、人間が理解できる形で説明することが困難なのである。
- 説明可能性への取り組み: モデルの解釈可能性を高めるための研究も進んでいる。一つのアプローチは、自己注意機構の「アテンションウェイト」を分析することである。アテンションウェイトは、モデルが予測を行う際にどの特徴量を重視したかを示す指標となり、特徴量の重要度を可視化する手がかりを与える<sup>61</sup>。しかし、アテンションが必ずしもモデルの判断根拠を忠実に反映しているとは限らないという指摘もあり、その解釈には慎重さが求められる。より進んだアプローチとして、TabSRAのように、解釈可能性をモデルアーキテクチャ自体に組み込む「自己説明的(self-explainable)」なモデルの研究も行われている<sup>72</sup>。これらのモデルは、その内部ロジックが本質的に透明であることを目指すが、まだ研究開発の途上にある。

## データ希少性と不均衡への対応

不正検知の分野では、データに関する二つの根源的な課題、すなわち「ラベル付きデータの希少性」と「クラスの極端な不均衡」が常に存在する。

- データ拡張技術: 深層学習の文脈では、この不均衡問題に対処するために、生成モデルを活用するアプローチが探求されている。特に、敵対的生成ネットワーク(GANs)を用いて、本物の不正データに酷似した高品質な合成データを生成し、少数派クラスのデータを増強してモデルを訓練する研究が行われている<sup>8</sup>。

- 自己教師あり学習の役割: ラベル付きデータが希少であるという課題に対しては、前述の通り、自己教師あり学習(SSL)が最も有望な解決策として期待されている。SSLは、大量のラベルなしデータからデータの構造を学習することで、ラベル付きデータへの依存を減らす。GraphGuardlにおけるコントラスト学習(対照学習)のような高度なSSL技術は、正常なパターンと異常なパターンをより効果的に分離するための表現を学習することを可能にし、この分野の研究を前進させている。

## 将来の展望

BNPL不正検知の技術は、今後以下の方向性で進化していくと考えられる。

- グラフトランスフォーマー: 時間的側面と関係的側面を統一的に扱うことができるこのアーキテクチャは、次世代の不正検知モデルの有力候補であり、さらなる研究開発が期待される。
- 高度な自己教師あり学習: 単純な事前学習に留まらず、より洗練されたSSL技術が導入されることで、モデルの表現学習能力と汎化性能がさらに向上するだろう。
- 連合学習(Federated Learning): データプライバシーの問題は、金融業界におけるデータ共有の大きな障壁となっている。連合学習は、各金融機関が自社の機密データを外部に出すことなく、共同で一つの強力な不正検知モデルを訓練することを可能にする技術である。この技術が成熟すれば、業界全体で不正パターンに関する知見を共有し、より広範で堅牢な防御網を構築することが可能になるだろう。

---

## 第8章 結論と戦略的提言

本サーベイは、後払い決済(BNPL)における不正検知技術の現状を分析し、特にTransformerアーキテクチャを中心とした深層学習モデルの可能性と課題を明らかにした。勾配ブースティング決定木(GBDT)が依然として堅牢な業界標準である一方、Transformerは、特に大規模データを活用した際に、それを凌駕する性能を発揮するポテンシャルを秘めている。しかし、その実用化には、計算コスト、リアルタイム性、解釈可能性といった複数の障壁が存在する。

### 結論の要約

- 現状の最適解としてのGBDT: BNPL不正検知の現場において、GBDTは依然として最も実績があり、コスト効率の高いソリューションである。その高い性能は、アルゴリズム自体の優秀さに加え、ドメイン知識を反映した特徴量エンジニアリングというエコシステムに支えられている。

- 条件付きの優位性を持つ**Transformer**: FT-Transformerに代表される表形式データ向けTransformerは、深層学習における最先端のアプローチであるが、そのGBDTに対する優位性は普遍的なものではなく、データセットやタスクの性質に依存する。
- パラダイムシフトの鍵としての自己教師あり学習: Transformerの真の価値は、そのアーキテクチャが大規模な自己教師あり学習(SSL)を可能にする点にある。GBDTがアクセスできない膨大なラベルなしデータを活用し、事前学習を行うことで、Transformerはデータの根源的な構造を学習し、少量のラベル付きデータでは到達し得ない高い汎化性能を獲得する。このパラダイムシフトこそが、不正検知の精度を次のレベルに引き上げるための鍵である。
- 実用化への重大な課題: Transformerの広範な導入を阻む最大の要因は、リアルタイム推論におけるレイテンシと、規制遵守の観点から求められるモデルの解釈可能性である。これらのエンジニアリング上およびガバナンス上の課題を解決しない限り、その導入は限定的なものに留まるだろう。

## 技術リーダーへの戦略的提言

以上の分析に基づき、BNPLサービスを提供する企業の技術リーダー(機械学習エンジニア、データサイエンティスト、AI研究リーダーなど)に対し、以下の段階的な戦略を提言する。

- フェーズ1: 基盤の確立(現在)
  - **GBDTベースラインの徹底的な最適化**: これから不正検知システムを構築する、あるいは既存システムを改良するチームは、まずGBDT(LightGBMやXGBoost)をベースラインとして採用し、その性能を極限まで高めるべきである。これは、現時点で最も費用対効果の高いアプローチである。
  - 特徴量エンジニアリングと不均衡データ対応の習熟: ユーザー行動の集約、速度チェック、特徴量間の相互作用など、高度な特徴量エンジニアリングの技術を磨き、組織のノウハウとして蓄積する。同時に、SMOTEなどの手法を用いて不均衡データに効果的に対処する能力を確立する。
- フェーズ2: 戦略的研究開発(1~2年後)
  - **Transformerの探索的研究を開始**: 成熟したGBDTシステムを運用しているチームは、Transformerを即時的な代替技術としてではなく、長期的な能力構築のための戦略的研究開発(R&D)イニシアティブとして位置づけるべきである。
  - データ戦略の策定: 将来の事前学習を見据え、ラベルの有無にかかわらず、全てのトランザクションデータを収集・処理・保存するためのデータインフラストラクチャの構築を開始する。
  - 概念実証(**Proof-of-Concept**)の実施: Booking.comの研究などを参考に、自社のデータを用いてオフラインでの性能評価を行う。まずはレイテンシが制約とならないバッチ処理型のスコアリングタスク(例: 夜間バッチでのリスク再評価)を対象とし、GBDTに対する潜在的な性能向上幅を検証する。
  - インフラとMLOpsへの投資: 大規模深層学習モデルの訓練、および推論時の最適化(量子化、コンパイル)に対応可能なGPUインフラと、それを支えるMLOps(機械学習基盤)への投資を計画的に開始する。



- フェーズ3: 次世代システムへの移行(3年以上先)
  - フロンティア技術の継続的な監視: グラフトランスフォーマー、自己説明可能AI(XAI)、連合学習といった最先端技術の動向を注視し続ける。
  - ハイブリッドシステムの構想: 将来の不正検知システムは、単一のモデルではなく、複数の技術を組み合わせたハイブリッドな形態になる可能性が高い。グラフの持つ関係性分析能力、Transformerの持つ表現学習能力、そして最適化された推論エンジンの持つ速度を統合し、同時に規制要件を満たす解釈可能性を備えたシステムの実現を長期的なビジョンとして掲げるべきである。

この段階的アプローチにより、企業は現在のビジネスニーズに確実に応えつつ、将来の技術革新の波に乗り遅れることなく、持続的に不正検知能力を進化させていくことが可能となる。

## 引用文献

1. 日本 後払い 市場規模、シェア、動向、成長、需要予測 2025-2033年 - NEWS CAST, 8月 23, 2025にアクセス、<https://newscast.jp/news/8202038>
2. 日本 後払い 市場規模、シェア、動向、成長、需要予測 2025-2033年 | IMARC Group, 8月 23, 2025にアクセス、<https://www.atpress.ne.jp/news/8202038>
3. 2023年度の後払い決済サービス市場規模は1.5%増の1兆5317億円、2028年度に2.8兆円まで拡大すると予測 | ネットショップ担当者フォーラムお悩み相談室, 8月 23, 2025にアクセス、<https://b-soudan.impress.co.jp/article/detail/1156>
4. Leveraging Machine Learning to Detect Fraud: Tips to Developing a Winning Kaggle Solution | NVIDIA Technical Blog, 8月 23, 2025にアクセス、<https://developer.nvidia.com/blog/leveraging-machine-learning-to-detect-fraud-tips-to-developing-a-winning-kaggle-solution/>
5. How the Magic Works - IEEE-CIS Fraud Detection | Kaggle, 8月 23, 2025にアクセス、<https://www.kaggle.com/competitions/ieee-fraud-detection/discussion/111453>
6. IEEE-CIS Fraud Detection - Kaggle, 8月 23, 2025にアクセス、<https://www.kaggle.com/competitions/ieee-fraud-detection/discussion/111735>
7. 6th place solution: The Zoo | Kaggle, 8月 23, 2025にアクセス、<https://www.kaggle.com/competitions/ieee-fraud-detection/writeups/the-zoo-6th-place-solution-the-zoo>
8. Year-over-Year Developments in Financial Fraud Detection via Deep Learning: A Systematic Literature Review - arXiv, 8月 23, 2025にアクセス、<https://arxiv.org/html/2502.00201v2>
9. arXiv:2502.00201v1 [cs.LG] 31 Jan 2025, 8月 23, 2025にアクセス、<https://arxiv.org/pdf/2502.00201?>
10. Credit Card Fraud Detection Using Advanced Transformer ... - arXiv, 8月 23, 2025にアクセス、<https://arxiv.org/pdf/2406.03733>
11. (PDF) Deep Learning for Credit Card Fraud Detection: A Review of Algorithms, Challenges, and Solutions - ResearchGate, 8月 23, 2025にアクセス、[https://www.researchgate.net/publication/382187222\\_Deep\\_Learning\\_for\\_Credit\\_Card\\_Fraud\\_Detection\\_A\\_Review\\_of\\_Algorithms\\_Challenges\\_and\\_Solutions](https://www.researchgate.net/publication/382187222_Deep_Learning_for_Credit_Card_Fraud_Detection_A_Review_of_Algorithms_Challenges_and_Solutions)
12. Credit Card Fraud Detection Using Advanced Transformer Model - SciSpace, 8月



- 23, 2025にアクセス、  
<https://scispace.com/pdf/credit-card-fraud-detection-using-advanced-transformer-model-2ueae0zzyh.pdf>
13. All About Transformer Inference | How To Scale Your Model - GitHub Pages, 8月 23, 2025にアクセス、<https://jax-ml.github.io/scaling-book/inference/>
14. Hugging Face Transformer Inference Under 1 Millisecond Latency - Medium, 8月 23, 2025にアクセス、  
<https://medium.com/data-science/hugging-face-transformer-inference-under-1-millisecond-latency-e1be0057a51c>
15. Fraud Detection with AI: Ensemble of AI Models Improve Precision & Speed - YouTube, 8月 23, 2025にアクセス、  
[https://www.youtube.com/watch?v=Mo7JMC\\_oDI](https://www.youtube.com/watch?v=Mo7JMC_oDI)
16. Year-over-Year Developments in Financial Fraud Detection via Deep Learning: A Systematic Literature Review - arXiv, 8月 23, 2025にアクセス、  
<https://arxiv.org/html/2502.00201v1>
17. GMOペイメントサービス: BtoC向け後払い決済、BtoB向け掛け払い決済サービスをご提供, 8月 23, 2025にアクセス、<https://www.gmo-ps.com/>
18. BNPLサービス「アトカラ」提供開始【GMOペイメント ... - PR TIMES, 8月 23, 2025にアクセス、<https://prtimes.jp/main/html/rd/p/000004303.000000136.html>
19. 市場規模4200億円の 後払い決済サービス市場で「NP 後払い」が約50%のシェアを獲得！ 年間ユニークユーザーは1200万人を突破し、日本人の10人に1人が利用！～より多くのユーザー, 8月 23, 2025にアクセス、  
<https://www.netprotections.com/news/20180508/>
20. 後払いアプリおすすめ38選！ 審査なしですぐ使える最新の決済サービス | 結心会マネースクール, 8月 23, 2025にアクセス、<https://www.kessin.or.jp/finance/bnpl/>
21. 後払い決済サービスとは: 7つのアプリ比較【2025年版】 - Shopify 日本, 8月 23, 2025にアクセス、<https://www.shopify.com/jp/blog/bnpl-companies>
22. コンビニ後払い決済なら「NP後払い」法人向けサイト, 8月 23, 2025にアクセス、  
<https://www.netprotections.com/>
23. BNPL(後払い決済)サービス「アトカラ」でVポイントサービスを開始 - GMOインターネットグループ, 8月 23, 2025にアクセス、<https://group.gmo/news/article/9467/>
24. ペイディみたいなアプリ16選！ 審査なしで登録できるおすすめのアプリも紹介 - アキ・オフィス, 8月 23, 2025にアクセス、  
<https://www.aki-office.com/column/like-paidy-apps/>
25. GMO後払いとは？機能、特徴やメリット | PRONIアイミツ SaaS, 8月 23, 2025にアクセス、  
<https://saas.imitsu.jp/cate-payment/service/2854>
26. GMO後払い決済サービス | 決済代行サービスの導入ならGMOペイメントゲートウェイ, 8月 23, 2025にアクセス、  
<https://www.gmo-pg.com/service/mulpay-atobarai/>
27. GMO後払いとは？評判・口コミや料金について - SheepDog, 8月 23, 2025にアクセス、  
[https://sheepdog.co.jp/late\\_payment/gmo\\_atobarai/](https://sheepdog.co.jp/late_payment/gmo_atobarai/)
28. GMO後払い(ジーエムオー後払い)の評判・特徴・料金を徹底解説！ - 起業LOG SaaS, 8月 23, 2025にアクセス、  
<https://kigyolog.com/tool.php?id=934>
29. GMO後払いの支払い方法は？NP後払いとの違いやメリット・デメリットも紹介, 8月 23, 2025にアクセス、  
<https://fackomi.com/column/gmo-deferred-payment-method/>
30. GMO後払い「請求書スマホ支払い」で商品購入から代金支払いまで自宅で可能に／

- GMO-PS, 8月 23, 2025にアクセス、<https://group.gmo/news/article/6858/>
31. NP掛け払い・NP後払いによるいたずら(なりすまし)とネットプロテクションズの対応, 8月 23, 2025にアクセス、<https://www.aster-link.co.jp/posts/np-kakebarai/>
  32. あと払いペイディ | 安全への取り組み | 翌月後払いのPaidy, 8月 23, 2025にアクセス、<https://paidy.com/security/>
  33. 【楽天市場】ヘルプ・お問い合わせ【ご注意】「NP後払い」を装った不審なメール, 8月 23, 2025にアクセス、<https://ichiba-smp.faq.rakuten.net/detail/000039208>
  34. 詐欺やトラブルに関するご注意 - ペイディカスタマーサポート, 8月 23, 2025にアクセス、  
<https://cs-support.paidy.com/support/solutions/articles/150000181634-%E8%A9%90%E6%AC%BA%E3%82%84%E3%83%88%E3%83%A9%E3%83%96%E3%83%AB%E3%81%AB%E9%96%A2%E3%81%99%E3%82%8B%E3%81%94%E6%B3%A8%E6%84%8F>
  35. 不正検知サービスおすすめ6選を徹底比較 | 特徴や選び方を解説, 8月 23, 2025にアクセス、[https://siws.dgbt.jp/blog/frauddetection\\_comparison](https://siws.dgbt.jp/blog/frauddetection_comparison)
  36. 不正行為検出の仕組み: 一般的なソフトウェアとツール - F5, 8月 23, 2025にアクセス、[https://www.f5.com/ja\\_jp/glossary/fraud-detection](https://www.f5.com/ja_jp/glossary/fraud-detection)
  37. Paidyの安心安全への取り組み, 8月 23, 2025にアクセス、  
<https://paidy.com/column/article/11Prxr8LzJXoZgcaUD9zz5/>
  38. 1月に詐欺発生の「Paidy」、再発防止にAI活用 顔認証で本人確認、不正取引を早期に検知, 8月 23, 2025にアクセス、  
<https://www.itmedia.co.jp/news/articles/2003/12/news125.html>
  39. やさしい後払い決済「atone(アトネ)」に、e-KYC本人確認API「TRUSTDOCK」を導入実施, 8月 23, 2025にアクセス、  
<https://biz.trustdock.io/news/ekyc-atone-netprotections>
  40. カードがいない、やさしい後払い決済「atone(アトネ)」に、e-KYC本人確認API「TRUSTDOCK」を導入実施 - ASCII.jp, 8月 23, 2025にアクセス、  
<https://ascii.jp/elem/000/004/015/4015274/>
  41. カードがいない やさしい後払い決済「atone(アトネ)」に、WEB版e-KYC「TRUSTDOCKアップローダー」による犯収法準拠の本人確認を導入, 8月 23, 2025にアクセス、<https://biz.trustdock.io/news/ekyc-api-atone-2>
  42. Winning solutions of kaggle competitions, 8月 23, 2025にアクセス、  
<https://www.kaggle.com/code/sudalairajkumar/winning-solutions-of-kaggle-competitions>
  43. [1st Place Solution] My Betting Strategy - Kaggle, 8月 23, 2025にアクセス、  
<https://www.kaggle.com/competitions/home-credit-credit-risk-model-stability/discussion/508337>
  44. 2nd place solution ( team ikiri\_DS ) - Kaggle, 8月 23, 2025にアクセス、  
<https://www.kaggle.com/competitions/home-credit-default-risk/writeups/ikiri-ds-2nd-place-solution-team-ikiri-ds>
  45. Give Me Some Credit | Kaggle, 8月 23, 2025にアクセス、  
<https://www.kaggle.com/competitions/GiveMeSomeCredit/discussion/300684>
  46. Data Science Competition-Credit Risk Prediction | Kaggle, 8月 23, 2025にアクセス、  
<https://www.kaggle.com/competitions/gs-l1-credit-risk-assessment>
  47. arunm8489/IEEE-CIS-Fraud-detection - GitHub, 8月 23, 2025にアクセス、

- <https://github.com/arunm8489/IEEE-CIS-Fraud-detection>
48. Home Credit - Credit Risk Model Stability | Kaggle, 8月 23, 2025にアクセス、  
<https://www.kaggle.com/competitions/home-credit-credit-risk-model-stability>
  49. AML/CFT対策におけるAI活用と管理 - 日本金融監査協会, 8月 23, 2025にアクセス、  
[https://www.ifra.jp/pdf/2021/1/118\\_web.pdf](https://www.ifra.jp/pdf/2021/1/118_web.pdf)
  50. 不正口座を検知する新AIエンジンを開発、安心・安全な金融サービス環境の実現へまた一歩 - ラック, 8月 23, 2025にアクセス、  
[https://www.lac.co.jp/lacwatch/report/20230524\\_003388.html](https://www.lac.co.jp/lacwatch/report/20230524_003388.html)
  51. 実用化への大きな一歩を踏み出した、金融不正取引抑止におけるAI活用 | LAC WATCH - ラック, 8月 23, 2025にアクセス、  
[https://www.lac.co.jp/lacwatch/service/20211022\\_002756.html](https://www.lac.co.jp/lacwatch/service/20211022_002756.html)
  52. 分類問題のデータ不均衡を解消するSMOTE(Python版) - その1 - セールスアナリティクス, 8月 23, 2025にアクセス、  
<https://www.salesanalytics.co.jp/datascience/datascience210/>
  53. 不均衡データの対策方法と評価指標！SmoteをPythonで実装して検証していく！ - スタビジ, 8月 23, 2025にアクセス、  
<https://toukei-lab.com/imbalance-data-smote>
  54. 不均衡データに対する機械学習: 理論と実践 - tomtom58's blog, 8月 23, 2025にアクセス、  
<https://tomtom58.hatenablog.com/entry/2025/04/19/182624>
  55. クラス不均衡データにおける機械学習モデルの構築 - codemajinのえんとろびい, 8月 23, 2025にアクセス、  
<https://www.codemajin.net/imbanced-ml-building/>
  56. 機械学習における不均衡データ対策 (2024) - Qiita, 8月 23, 2025にアクセス、  
<https://qiita.com/futakuchi0117/items/92d03fa35e196713c3ac>
  57. データの不均衡をオーバーサンプリングで解消するSMOTEの解説と実装例, 8月 23, 2025にアクセス、  
<https://tech.aru-zakki.com/smote/>
  58. Enhanced Credit Card Fraud Detection Using Deep Hybrid CLST Model - MDPI, 8月 23, 2025にアクセス、  
<https://www.mdpi.com/2227-7390/13/12/1950>
  59. Enhanced credit card fraud detection based on attention mechanism and LSTM deep model, 8月 23, 2025にアクセス、  
<https://d-nb.info/1251302696/34>
  60. AI-powered real-time fraud detection across hybrid cloud architectures using stream processing and deep learning, 8月 23, 2025にアクセス、  
<https://ijrsra.net/sites/default/files/IJSRA-2024-1978.pdf>
  61. Financial Fraud Detection with Self-Attention Mechanism: A Comparative Study - Journal of Computer Science and Software Applications, 8月 23, 2025にアクセス、  
<https://mfacademia.org/index.php/jcssa/article/download/179/156/312>
  62. TabTransformer: Pay more attention to Structured data - Kaggle, 8月 23, 2025にアクセス、  
<https://www.kaggle.com/general/302021>
  63. Mastering Tabular Data with TabTransformer: A Comprehensive ..., 8月 23, 2025にアクセス、  
<https://aravindkolli.medium.com/mastering-tabular-data-with-tabtransformer-a-comprehensive-guide-119f6dbf5a79>
  64. Benchmark datasets. All datasets are binary classification tasks.... | Download Scientific Diagram - ResearchGate, 8月 23, 2025にアクセス、  
[https://www.researchgate.net/figure/Benchmark-datasets-All-datasets-are-binary-classification-tasks-Positive-Class-is-the\\_tbl2\\_347124498](https://www.researchgate.net/figure/Benchmark-datasets-All-datasets-are-binary-classification-tasks-Positive-Class-is-the_tbl2_347124498)
  65. A Self-Attention-Based Imputation Technique for Enhancing Tabular Data Quality

- MDPI, 8月 23, 2025にアクセス、<https://www.mdpi.com/2306-5729/8/6/102>
66. Revisiting Deep Learning Models for Tabular Data - arXiv, 8月 23, 2025にアクセス、<https://arxiv.org/pdf/2106.11959>
67. Revisiting Deep Learning Models for Tabular Data - OpenReview, 8月 23, 2025にアクセス、[https://openreview.net/pdf?id=i\\_Q1yrOegLY](https://openreview.net/pdf?id=i_Q1yrOegLY)
68. [2406.03733] Credit Card Fraud Detection Using Advanced Transformer Model - arXiv, 8月 23, 2025にアクセス、<https://arxiv.org/abs/2406.03733>
69. Transformer-Based Financial Fraud Detection with Cloud-Optimized Real-Time Streaming - arXiv, 8月 23, 2025にアクセス、<https://arxiv.org/pdf/2501.19267>
70. Detecting Financial Fraud in Listed Companies via a CNN-Transformer Framework, 8月 23, 2025にアクセス、<https://www.preprints.org/manuscript/202502.0891/v1>
71. Deploy large models at high performance using FasterTransformer on Amazon SageMaker, 8月 23, 2025にアクセス、<https://aws.amazon.com/blogs/machine-learning/deploy-large-models-at-high-performance-using-fastertransformer-on-amazon-sagemaker/>
72. TabSRA: An Attention based Self-Explainable Model for Tabular ..., 8月 23, 2025にアクセス、<https://www.esann.org/sites/default/files/proceedings/2023/ES2023-37.pdf>
73. Gated attention based generative adversarial networks for imbalanced credit card fraud detection - PeerJ, 8月 23, 2025にアクセス、<https://peerj.com/articles/cs-2972.pdf>
74. [2501.19267] Transformer-Based Financial Fraud Detection with Cloud-Optimized Real-Time Streaming - arXiv, 8月 23, 2025にアクセス、<https://arxiv.org/abs/2501.19267>